

Universidade do Porto
Faculdade de Ciências

Homicídios em Diferentes Condados dos Estados Unidos da América

Relatório Detalhado de Projeto

Realizado por Mafalda Carmo (202207123), Marta Monteiro (202509295) e
Rafaela Pinto (202004330)

1 Introdução

Este projeto tem como objetivo a análise numérica e gráfica de dados, em R, de um *dataset* com diferentes tipos de variáveis, para consolidação dos conhecimentos adquiridos na cadeira de Estatística Computacional.

O *dataset* escolhido foi o ***countymurders*** do *package* ***wooldridge*** do R. Selecionou-se apenas os dados do ano de 1980 e restringiu-se a densidade populacional até 11000, para facilitar o processo de análise.

Com a variável de densidade populacional (que posteriormente foi descartada) criou-se uma variável categórica ***density_cat***, distribuindo-a por quartis, para haver uma distribuição uniforme de dados e foram retiradas do *dataset* as linhas onde houvesse falta de observações em alguma das variáveis (*NA values*), para, mais uma vez, facilitar a análise.

Por último, foi criada uma nova variável categórica ***highmrdzone_var*** que indica, com o valor 1, se o respetivo *county* tem um valor elevado de homicídios, e, indica, com o valor 0, se o *county* não tem um valor elevado de homicídios. Neste projeto, 26 foi considerado um número elevado de homicídios num ano.

Portanto o estado final do *dataset* contém 8 variáveis: ***arrests***, ***perc1019***, ***perc2029***, ***perblack***, ***percmale***, ***murders***, ***density_cat*** e ***highmrdzone_var***.

2 Problema

O problema fundamental que queremos resolver com esta análise é se poderá haver alguma relação entre o tipo de população (população mais jovem; com alta percentagem de pessoas de raça negra; com alta percentagem de homens; com uma elevada densidade populacional) e o número de homicídios.

3 Análise do Dados

3.1 Análise Numérica

O *dataset* trabalhado vai ser chamado, daqui em diante, de *data2*. Para esta análise numérica, usámos também mais 2 *datasets*, que são originados de *data2*: *HighMrdZone*, onde estão os dados dos *counties* onde o número de homicídios é superior a 25 (***murders*** > 25); *NHighMrdZone*, que é o *dataset* complementar de *HighMrdZone*.

Analisámos cada variável na amostra total, nas zonas com alto número de homicídios e nas restantes zonas (ou seja, em *data2*, *HighMrdZone* e em *NHighMrdZone*) para ver se encontrávamos diferenças significativas que nos pudessem indicar possíveis relações sobre o tipo de população e o valor de ***murders***.

3.1.1 Variável *arrests*

Começamos por analisar a variável discreta *arrests*, que indica o número de detenções em cada *county* nesse ano (1980). Fizemos os histogramas (de densidade) e *boxplots* para analisarmos a simetria dos dados desta variável. Aqui o uso de histogramas é aceitável, pois, embora a variável seja discreta, esta assume muitos valores diferentes.




Figure 1: Histogramas e Boxplots para Análise da variável *arrests*

Claramente, estes dados são muito assimétricos, portanto vamos descrevê-los pela sua mediana e diferença interquartil.

	data2	HighMrdZone	NHighMrdZone
median	1	43	1
IQR	4	42	3

Table 1: Tabela com os valores da mediana (*median*) e diferença interquartil (IQR) dos dados da variável *arrests*, na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.

Os valores em *HighMrdZone* são muito diferentes (e muito mais elevados) dos restantes valores. Será uma diferença significativa?




Figure 2: Boxplots para Análise da Relação da variável **arrests** com a variável **highmrdzone_var**, sem e com restrição em y, respetivamente.

Na Figura 2 são apresentados dois boxplots que ilustram a relação entre o número de **arrests** e a variável **highmrdzone_var**. O primeiro gráfico mostra a distribuição completa dos dados, incluindo os outliers, enquanto o segundo apresenta a mesma distribuição, mas com uma restrição no eixo dos valores de **arrests**, de forma a reduzir o impacto visual dos valores extremos. Ao restringir o eixo, é possível visualizar com maior clareza a mediana e a dispersão da maioria dos dados, o que permite uma análise mais detalhada das diferenças entre as categorias de **highmrdzone_var**.

Estes resultados sugerem uma relação positiva entre a variável **highmrdzone_var** e o número de **arrests**, o que é consistente com a expectativa de que zonas com mais registos de criminalidade tendem também a registar, consequentemente, mais detenções.

Fizemos um teste de Wilcoxon (pois não estamos a trabalhar com dados com uma distribuição normal) com o modelo de **arrests** em prol de **highmrdzone_var** e obtivemos um $p\text{-value} < 2.2 \times 10^{-16}$.

Ou seja, a probabilidade de obtermos estes dados sob a hipótese de que a diferença entre as medianas de **arrests** em *HighMrdZone* e *NHighMrdZone* é aproximadamente zero é menor que 2.2×10^{-16} . Logo, a diferença de medianas é significativa, o que indica uma possível relação entre o número de homicídios e o número de detenções - algo que seria esperado.

3.1.2 Variável *perc1019*

Seguimos para a análise da variável contínua ***perc1019***, que indica a percentagem da população do *county* que tem a idade compreendida entre 10 e 19 anos. Vamos analisar os respetivos histogramas e *boxplots*:




Figure 3: Histogramas e Boxplots para Análise da variável ***perc1019***

Estes dados apresentam simetria, pois a mediana nos *boxplots* está a meio da "caixa", a distância da caixa a cada um dos extremos é igual e os *outliers* aparecem igualmente distribuídos dos dois lados. Sendo assim, vamos descrever esta variável através da média e do erro padrão.

	data2	HighMrdZone	NHighMrdZone
mean	17.672	17.339	17.687
sd	1.690	1.294	1.705

Table 2: Tabela com valores da média (*mean*) e do erro padrão (*standard deviation* - *sd*) dos dados da variável ***perc1019***, na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.




Figure 4: Boxplots para Análise da Relação da variável ***perc1019*** com a variável ***highmrdzone_var***.

Mas não parece haver uma relação entre a percentagem da população com a idade compreendida entre os 10 e os 19 anos e o número de homicídios. Analisaremos melhor na secção de análise gráfica.

Ao fazer um *t-test* do modelo ***perc1019*** em prol de ***highmrdzone_var***, obtivemos o *p-value* igual a 0.014, logo, embora os valores sejam muito semelhantes, o teste detetou uma diferença significativa entre eles, devido ao erro padrão ser pequeno e o tamanho da amostra grande.

3.1.3 Variável ***perc2029***

Agora vamos analisar a variável contínua ***perc2029***, que indica a percentagem da população com idade compreendida entre os 20 e os 29 anos. No entanto, daqui para a frente, não vamos mostrar os histogramas nem os *boxplots*, para não estender muito o tamanho do relatório.

Mais uma vez, os dados são muito assimétricos, portanto iremos descrevê-los pela sua mediana e diferença interquartil.

	data2	HighMrdZone	NHighMrdZone
median	15.860	18.650	15.750
IQR	2.945	2.440	2.735

Table 3: Tabela com os valores da mediana (*median*) e diferença interquartil (IQR) dos dados da variável ***perc2029***, na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.




Figure 5: Boxplots para Análise da Relação da variável ***perc2029*** com a variável ***highmrdzone_var***.

Em geral, a Figura 5 sugere uma pequena relação positiva entre as variáveis ***perc2029*** e ***highmrdzone_var***.

Complementando esta análise, um teste de Wilcoxon com o modelo de ***perc2029*** em prol de ***highmrdzone_var*** foi realizado e obtivemos um $p\text{-value} < 2.2 \times 10^{-16}$, que revela uma diferença bastante significativa das medianas. Vamos analisar melhor esta relação na secção de análise gráfica.

3.1.4 Variável ***percblack***

De seguida, analisaremos a variável contínua ***percblack***, que indica a percentagem de população de raça negra. Devido à forte assimetria destes dados, optaremos por descrevê-los utilizando a mediana e o intervalo interquartil.

	data2	HighMrdZone	NHighMrdZone
median	1.400	10.840	1.150
IQR	8.710	13.910	7.392

Table 4: Tabela com os valores da mediana (*median*) e diferença interquartil (IQR) dos dados da variável ***percblack***, na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.

Mais uma vez, vemos uma diferença grande entre os valores de *HighMrdZone* e *NHighMrdZone*. E fizemos um teste de Wilcoxon que corroborou a ideia de que estes valores têm uma diferença significativa.




Figure 6: Boxplots para Análise da Relação da variável ***percblack*** com a variável ***highmrdzone_var***.

Este gráfico sugere também uma pequena relação entre as duas variáveis, mas pode ser uma relação sem relevância prática, embora tenha significância estatística.

3.1.5 Variável ***percmale***

Em seguida, examinaremos a variável contínua ***percmale*** que representa a percentagem de população masculina.

Dada a aproximada simetria dos dados, vamos descrever esta variável através da sua média e do erro padrão.

	data2	HighMrdZone	NHighMrdZone
mean	41.369	40.965	41.388
sd	1.591	1.293	1.602

Table 5: Tabela com valores da média (*mean*) e do erro padrão (*standard deviation* - *sd*) dos dados da variável ***percmale***, na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.

Aqui a diferença dos valores é mínima, mas fazendo um *t-test* obtemos um *p-value*= 0.003, logo esta diferença tem significância estatística, pela razão que já enunciámos anteriormente, quando analisámos a variável ***perc1019***.




Figure 7: Boxplots para Análise da Relação da variável *percmale* com a variável *highmrdzone_var*.

Esta figura vai de encontro com os dados obtidos na tabela. Mostra uma pequena diferença na percentagem de população masculina entre os dois tipos de zonas. Não nos sugere nenhum tipo de relação entre as variáveis *murders* e *percmale*.

3.1.6 Variável *murders*

Na sequência, investigaremos a variável discreta *murders* que indica o número de assassinatos em cada *county* no ano 1980. Dada a assimetria observada, analisaremos a variável através da mediana e do intervalo interquartil.

	data2	HighMrdZone	NHighMrdZone
median	1	48	1
IQR	4	60	3

Table 6: Tabela com os valores da mediana (*median*) e diferença interquartil (IQR) dos dados da variável *murders*, na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.

A mediana e a dispersão (IQR) são muito maiores nas zonas de alta criminalidade, o que era de prever, pois estas duas zonas foram definidas pelo valor de homicídios que lá ocorrem. Portanto, estes resultados são triviais.




Figure 8: Boxplots para Análise da relação da variável ***murders*** com a variável ***highmrdzone_var***, sem e com restrição em y, respetivamente.

Quando se plota sem limitar o eixo Y, as diferenças são difíceis de ver por causa dos outliers extremos. Ao restringir o eixo y, a diferença fica clara: o grupo 1 tem valores mais altos e variáveis e o grupo 0 tem valores baixos e pouca dispersão. Finalmente, o teste de wilcoxon mostra que há diferenças estatisticamente significativas entre o número de homicídios dos dois grupos o que vai ao encontro da definição de *HighMrdZone* e *NHighMrdZone*.

3.1.7 Variável ***density_cat***

Para finalizar a análise numérica, vamos explorar a variável categórica, ***density_cat***, que categoriza cada *county* em quatro níveis de densidade populacional, 'High', 'Upper-Mid', 'Lower-Mid' e 'Low'.

Para compreender a distribuição desta variável, apresentaremos a frequência absoluta e relativa de *county* em cada categoria, permitindo identificar padrões de concentração populacional e a sua potencial relação com a ocorrência de assassinatos.

	High	Upper-Mid	Lower-Mid	Low
data2	545	528	525	469
HighMrdZone	87	6	0	0
NHighMrdZone	458	522	525	469

Table 7: Tabela das Frequências Absolutas da variável categórica ***density_cat*** na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.

	High	Upper-Mid	Lower-Mid	Low
data2	26.4%	25.5%	25.4%	22.7%
HighMrdZone	93.5%	6.5%	0%	0%
NHighMrdZone	23.2%	26.4%	26.6%	23.8%

Table 8: Tabela das Frequências Relativas da variável categórica ***density_cat*** na amostra total, nas zonas com alto número de homicídios e nas restantes zonas.

Realizamos ainda o *Pearson's Chi-squared test* para avaliar a relação entre ***density_cat*** e ***highmrdzone_var***. O resultado indicou uma relação estatisticamente significativa entre as duas variáveis ($p\text{-value} < 2.2 \times 10^{-16}$), sugerindo que a distribuição das categorias de densidade populacional difere consoante o tipo de zona (alta ou não alta em homicídios). Estes números sugerem que as zonas com uma elevada taxa de homicídios, tendem a ter uma densidade populacional alta.

3.2 Análise gráfica

Para complementar a análise numérica, procedemos à exploração gráfica das variáveis em estudo. As visualizações de seguida apresentadas permitem identificar padrões, tendências e possíveis discrepâncias nos dados, oferecendo uma perspetiva mais intuitiva sobre as relações entre as variáveis e o comportamento das suas distribuições.




Figure 9: Violin Plot para Análise da Distribuição da variável ***perc2029*** em relação à variável ***highmrdzone_var***.

Aqui conseguimos analisar que condados com maiores taxas de homicídio tendem a ter uma percentagem de população 20–29 mais concentrada e um pouco mais elevada, enquanto condados com menos homicídios apresentam mais variabilidade, mas com predominância de valores mais baixos. No grupo com mais homicídios, a distribuição não só é mais concentrada, como mantém uma densidade considerável ao longo dos valores entre os 20 e poucos por cento, sugerindo que esta faixa etária é mais consistente e típica neste grupo. Ainda assim, não se verifica uma relação linear forte.



Figure 10: Violin Plot para Análise da Distribuição da variável *perc1019* em relação à variável *highmrldzone_var*.

Neste gráfico notam-se pequenas diferenças, visto que o grupo 1 (maior número de homicídios) é mais concentrado e tem um pico um pouco mais marcado. Porém, a semelhança das zonas de maior densidade (ambos entre 15–20%) mostra que esta variável não separa muito bem os dois grupos. Assim, esta variável revela apenas uma associação fraca com os níveis de homicídio, sobretudo quando comparada com a faixa etária 20–29. A faixa etária 10–19 não parece ser tão informativa como a faixa 20–29.

O seguinte gráfico permite avaliar eventuais relações entre algumas das variáveis.




Figure 11: Scatter Plot para Análise das relações entre as variáveis *murders*, *percblack*, *arrests* e *perc2029*.

Primeiramente, a análise dos eixos permite perceber se maior percentagem de população negra está associada a mais homicídios. Observa-se que condados com percentagem de população negra acima de 40% tendem a ter entre 0 a 20 homicídios. Os condados com mais homicídios (mais de 25) apresentam uma percentagem de população negra entre 0 e 40%.

apresentando uma concentração ligeiramente maior entre 0 e 20%.

Não há evidências visuais de um padrão ascendente claro, ou seja, de uma relação linear positiva forte entre a percentagem de população negra e o número de homicídios. Note-se que os condados com mais homicídios não são necessariamente os que têm maior percentagem de população negra.

Já as cores do gráfico remetem para a influência da percentagem de população de jovens adultos (20 a 29 anos) - faixa etária associada a maior criminalidade em diversos estudos criminais.

Observa-se uma presença relativamente equilibrada de pontos escuros tanto em regiões com muitos homicídios, como em regiões associadas a um menor número de homicídios. Isto sugere que a variável jovem também não tem um impacto notório no número de homicídios.

O tamanho dos pontos representa o número de detenções. É clara a maior concentração de pontos maiores em zonas onde o número de homicídios é mais alto. O gráfico sugere uma relação positiva clara entre o número de homicídios e o número de detenções, uma relação coerente e expectável.

Por último, note-se a distribuição da nuvem de pontos, por sinal bastante assimétrica, com muitos condados concentrados em homicídios baixos (0-10). A maioria dos condados apresenta baixos valores de homicídios, havendo alguns outliers com valores extremos.

A seguinte variação do gráfico anterior, em que se mudou apenas a interpretação da cor, que desta vez remete para a variável referente à percentagem de população entre 10 e 19 anos, sugere que esta variável também não tem influência direta no número de homicídios.




Figure 12: Scatter Plot para Análise das relações entre as variáveis *murders*, *percblack*, *arrests* e *perc1019*.




Figure 13: Violin Plot para Análise da Distribuição da variável *percblack* em relação à variável *highmrdzone_var*

Os condados com poucos homicídios apresentam uma grande concentração de valores baixos de percentagem de população negra, o que vai ao encontro do aglomerado da nuvem de pontos visto no gráfico anterior.

Nos condados com muitos homicídios, a percentagem de população negra não é particularmente alta, apenas menos concentrada em valores tão baixos. O violino mostra uma distribuição mais uniforme, ou seja, sem uma concentração tão forte num intervalo específico. Isto também não implica uma relação linear, apenas mostra maior dispersão. Os gráficos sugerem que mais homicídios podem estar associados a percentagens um pouco maiores de população negra mas não temos uma relação linear particularmente forte.




Figure 14: Gráfico da relação entre o número de homicídios e o número de detenções, com a variável *percblack* representada com cor. Cada ponto representa uma observação.

Neste gráfico vemos, mais uma vez, que, embora haja uma diferença significativa entre as medianas de *percblack* em *HighMrdZone* e *NHighMrdZone*, não parece haver uma aparente relação entre o número de homicídios e a percentagem da população de raça negra.

O que dá para ver claramente, na figura 14, é que há uma relação entre *murders* e *arrests*. O gráfico sugere que o aumento do número de homicídios leva a um maior número de detenções.




Figure 15: Gráfico de Homicídios vs. Densidade Populacional, com a percentagem de população masculina representada nas cores dos pontos. Cada ponto representa uma observação.

Aqui reparámos que com o aumento do número de homicídios, não há uma diferença aparente na percentagem da população masculina, mas conseguimos ver que à medida que a densidade populacional aumenta, o valor de *murders* também aumenta.

4 Conclusão

Com a análise feita conseguimos concluir que uma zona com altos números de homicídios tende a ter uma maior densidade populacional e um maior número de detenções. Podemos observar também que, embora muitas das variáveis estudadas, apresentem diferenças com significância estatística, não têm relevância prática para a questão que foi estudada.

5 Declaração

Declaro que o presente relatório é de minha autoria e não foi utilizado previamente noutro curso ou unidade curricular, desta ou de outra instituição. As referências a outros autores (afirmações, ideias, pensamentos) respeitam escrupulosamente as regras da atribuição, e encontram-se devidamente indicadas no texto e nas referências bibliográficas, de acordo com as normas de referenciação. Tenho consciência de que a prática de plágio e auto-plágio constitui um ilícito académico.

Mafalda Carmo
Marta Monteiro
Rafaela Pinto